

SME0104 Cálculo Numérico

Aula 12

Maria Luísa Bambozzi de Oliveira
marialuisa @ icmc . usp . br
Sala: 3-241
Página: tidia-ae.usp.br

14 de abril de 2015



Sistemas Lineares:

- ▶ Métodos Exatos:
 - ▶ Método de Gauss Compacto: adaptação do Método de Gauss Simples para armazenar matrizes L e L na mesma matriz;
 - ▶ Método de Cholesky (decomposição GG^T de matrizes simétricas, positivas definidas);
- ▶ Mal Condicionamento;
- ▶ Matriz Inversa.

Vantagens sobre Métodos Exatos:

- ▶ Melhores (quando matriz A é esparsa);
- ▶ Mais econômicos (menos memória);
- ▶ Autocorreção, redução dos erros de arredondamento;
- ▶ Em certos casos: solução de eqs. não-lineares.

Desvantagem: não possui número fixo de passos para atingir a solução exata.

Norma de vetor \vec{x} : $\|\vec{x}\|$, é qualquer função definida em \mathbb{R}^n , com valores em \mathbb{R} , satisfazendo:

- ▶ $\|\vec{x}\| \geq 0$ e $\|\vec{x}\| = 0$ se e somente se $\vec{x} = \vec{0}$;
- ▶ $\|\lambda \vec{x}\| = |\lambda| \|\vec{x}\|$ para todo escalar λ ;
- ▶ $\|\vec{x} + \vec{y}\| \leq \|\vec{x}\| + \|\vec{y}\|$ (desigualdade triangular).

$$|\vec{x} \cdot \vec{y}| \leq \|\vec{x}\| \|\vec{y}\|.$$

Mais conhecidos: Se $\vec{x} = (x_1, x_2, \dots, x_n)^T \in \mathbb{R}^n$:

- ▶ $\|\vec{x}\|_\infty = \max_{1 \leq i \leq n} |x_i|$;
- ▶ $\|\vec{x}\|_1 = \sum_{i=1}^n |x_i|$;
- ▶ $\|\vec{x}\|_2 = \|\vec{x}\| = \sqrt{\sum_{i=1}^n x_i^2}$.

Exemplo: Normas de $\vec{x} = (1, 4, 3, -3, -1)$.

Norma de matriz A : $\|A\|$, é qualquer função definida no conjunto de matrizes $n \times n$, com valores em \mathbb{R} , satisfazendo:

- ▶ $\|A\| \geq 0$ e $\|A\| = 0$ se e somente se $A = \mathbf{0}$;
- ▶ $\|\lambda A\| = |\lambda| \|A\|$ para todo escalar λ ;
- ▶ $\|A + B\| \leq \|A\| + \|B\|$ (desigualdade triangular).

$$\|AB\| \leq \|A\| \|B\|.$$

Mais conhecidos: Se A é matriz $n \times n$:

- ▶ $\|A\|_{\infty} = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$ (norma linha);
- ▶ $\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$ (norma coluna);
- ▶ $\|A\|_2 = \|A\| = \sqrt{\sum_{i,j=1}^n a_{ij}^2}$ (norma euclidiana).

Um método é **iterativo** quando fornece sequência de aproximações da solução, repetindo o mesmo tipo de processo.

Métodos estacionários: cada aproximação é obtida da anterior sempre pelo mesmo processo.

Se processos variam de passo para passo mas se repetem ciclicamente de s em s passos, o processo é s -cíclico.

Os métodos iterativos exigem que sempre se saiba se a sequência que está sendo obtida está convergindo ou não para a solução desejada.

Definição: Dadas uma sequência de vetores $\vec{x}^k \in E$ e uma norma sobre E , onde E é um espaço vetorial, dizemos que a sequência $\{\vec{x}^k\}$ **converge** para $\vec{x} \in E$ se $\|\vec{x}^k - \vec{x}\| \rightarrow 0$ quando $k \rightarrow \infty$.

Sistema linear

$$A\vec{x} = \vec{b} \quad \sim \quad \vec{x} = B\vec{x} + \vec{g}$$

com solução \vec{x} .

Se $\vec{x}^{(0)}$ é aproximação inicial para \vec{x} , obtemos $\vec{x}^{(k)}$ usando

$$\vec{x}^{(k)} = B\vec{x}^{(k-1)} + \vec{g}, \quad k = 1, 2, \dots$$

Teorema: A condição **necessária e suficiente** para a convergência do processo iterativo é que $\max |\lambda_i| < 1$, onde λ_i são os autovalores da matriz B de iteração.

Corolário (Critério Geral de Convergência): O processo iterativo é convergente se, para qualquer norma de matrizes, $\|B\| < 1$.

Exemplo: Seja

$$B = \begin{pmatrix} 0,2 & -0,7 & 0,2 \\ 0,1 & 0,1 & -0,3 \\ 0,6 & 0,1 & -0,3 \end{pmatrix}$$

Verificar se um sistema linear $A\vec{x} = \vec{b}$, que tenha a matriz B anterior como matriz de iteração, convergirá para a solução.

$$\|B\|_{\infty} = \max\{1,1; 0,5; 1,0\} = 1,1 \geq 1 \Rightarrow ?$$

$$\|B\|_1 = \max\{0,9; 0,9; 0,8\} = 0,9 < 1 \Rightarrow \text{SIM}$$

Processo de Parada:

Quando aplicamos método iterativo escolhemos $\vec{x}^{(0)}$ como aproximação inicial para solução de $A\vec{x} = \vec{b}$.

Refinamos solução até determinada precisão ε ser atingida, verificada com *erro relativo*:

$$\|\vec{x}^{(k+1)} - \vec{x}^{(k)}\|_{\infty} < \varepsilon \max\{1, \|\vec{x}^{(k+1)}\|_{\infty}\}$$

Para cada método a ser determinado, do que precisamos? Matriz B e vetor \vec{g} para definir $\vec{x} = B\vec{x} + \vec{g}$.

Métodos:

- ▶ Método de Jacobi-Richardson (JR);
- ▶ Método de Gauss-Seidel (GS).

Sistema $A\vec{x} = \vec{b}$ com $\det(A) \neq 0$:

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n = b_2 \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \dots + a_{nn}x_n = b_n \end{cases}$$

Decompor A em $A = L + D + R$,

$$L: \quad \ell_{ij} = \begin{cases} a_{ij}, & i > j \\ 0, & i \leq j \end{cases}; \quad D: \quad d_{ij} = \begin{cases} a_{ij}, & i = j \\ 0, & i \neq j \end{cases};$$

$$R: \quad r_{ij} = \begin{cases} a_{ij}, & i < j \\ 0, & i \geq j \end{cases}.$$

$$A = L + D + R$$

Se $\det(D) \neq 0$:

$$(L + D + R)\vec{x} = \vec{b}$$

$$\Rightarrow D\vec{x} + (L + R)\vec{x} = \vec{b}$$

$$\Rightarrow D\vec{x} = -(L + R)\vec{x} + \vec{b}$$

$$\Rightarrow \vec{x} = -D^{-1}(L + R)\vec{x} + D^{-1}\vec{b}$$

\Downarrow

$$B = -D^{-1}(L + R); \quad \vec{g} = D^{-1}\vec{b}$$

$$A = L + \textcolor{red}{D} + R$$

$$D = \begin{pmatrix} a_{11} & 0 & \cdots & 0 & 0 \\ 0 & a_{22} & \cdots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \cdots & a_{n-1,n-1} & 0 \\ 0 & 0 & \cdots & 0 & a_{nn} \end{pmatrix}, \quad \det(D) \neq 0$$

$$\Rightarrow D^{-1} = \begin{pmatrix} \frac{1}{a_{11}} & 0 & \cdots & 0 & 0 \\ 0 & \frac{1}{a_{22}} & \cdots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \cdots & \frac{1}{a_{n-1,n-1}} & 0 \\ 0 & 0 & \cdots & 0 & \frac{1}{a_{nn}} \end{pmatrix}$$

$$A = L + D + R$$

$$\Rightarrow D^{-1}A = D^{-1}L + D^{-1}D + D^{-1}R$$

$$\Rightarrow D^{-1}A = D^{-1}L + I + D^{-1}R$$

$$\Rightarrow A^* = L^* + I + R^*$$

$$\vec{x}^{(k+1)} = -(L^* + R^*)\vec{x}^{(k)} + \vec{b}^*$$

$$L^* : \ell_{ij}^* = \begin{cases} a_{ij}^* = \frac{a_{ij}}{a_{ii}}, & i > j \\ 0, & i \leq j \end{cases}; \quad R^* : r_{ij}^* = \begin{cases} a_{ij}^* = \frac{a_{ij}}{a_{ii}}, & i < j \\ 0, & i \geq j \end{cases};$$

$$\vec{b}^* : b_i^* = \frac{b_i}{a_{ii}}.$$

Crítérios de Convergência:

Com $B = -(L^* + R^*)$, usando o Critério Geral de Convergência, escolhemos as normas $\|B\|_\infty$ e $\|B\|_1$ nessa ordem para a verificação:

- ▶ **Crítério das Linhas:**

$$\max_{1 \leq i \leq n} \sum_{j=1, j \neq i}^n |a_{ij}^*| < 1$$

- ▶ **Crítério das Colunas:**

$$\max_{1 \leq j \leq n} \sum_{i=1, i \neq j}^n |a_{ij}^*| < 1$$

- ▶ **Crítério Diagonal Dominante:**

$$\sum_{j=1, j \neq i}^n |a_{ij}| < |a_{ii}|, \quad i = 1, 2, \dots, n$$

Observação: BASTA APENAS **UM** DOS CRITÉRIOS.

Exemplo: Resolver o sistema linear

$$\begin{cases} 10x_1 + 2x_2 + x_3 = 7 \\ x_1 + 5x_2 + x_3 = -8 \\ 2x_1 + 3x_2 + 10x_3 = 6 \end{cases}$$

pelo método JR, com $\vec{x}^{(0)} = (7/10, -8/5, 3/5)^T$.

Verificar primeiro se há garantia de convergência.

Se há garantia, reescrever sistema tal que $A^* \vec{x} = \vec{b}^*$.

Aplicar as iterações do método JR:

$$\vec{x}^{(k+1)} = -(L^* + R^*) \vec{x}^{(k)} + \vec{b}^*.$$

Exemplo: Resolver o sistema linear

$$\begin{cases} 10x_1 + 2x_2 + x_3 = 7 \\ x_1 + 5x_2 + x_3 = -8 \\ 2x_1 + 3x_2 + 10x_3 = 6 \end{cases}$$

pelo método JR, com $\vec{x}^{(0)} = (7/10, -8/5, 3/5)^T$.

Critério Diagonal Dominante:

$$|2| + |1| = 3 < |10|$$

$$|1| + |1| = 2 < |5| \quad \Rightarrow \text{converge.}$$

$$|2| + |3| = 5 < |10|$$


$$\begin{cases} x_1 + 0,2x_2 + 0,1x_3 = 0,7 \\ 0,2x_1 + x_2 + 0,2x_3 = -1,6 \\ 0,2x_1 + 0,3x_2 + x_3 = 0,6 \end{cases}$$

Método de Jacobi-Richardson (cont.)

$$\begin{cases} x_1^{(k)} = 0,7 - 0,2x_2^{(k-1)} - 0,1x_3^{(k-1)} \\ x_2^{(k)} = -1,6 - 0,2x_1^{(k-1)} - 0,2x_3^{(k-1)} \\ x_3^{(k)} = 0,6 - 0,2x_1^{(k-1)} - 0,3x_2^{(k-1)} \end{cases}$$

k	x_1	x_2	x_3	$\ \vec{x}^{(k)} - \vec{x}^{(k-1)}\ _\infty$
0	0,70000	-1,60000	0,60000	-
1	0,96000	-1,86000	0,94000	0,34000
2	0,97800	-1,98000	0,96600	0,12000
3	0,99940	-1,98880	0,99840	0,03240
4	0,99792	-1,99956	0,99676	0,01076
5	1,00024	-1,99894	1,00028	0,00352
6	0,99976	-2,00010	0,99963	0,00116
7	1,00006	-1,99988	1,00008	0,00045
8	0,99997	-2,00003	0,99995	0,00015
9	1,00001	-1,99998	1,00001	0,00006
10	1,00000	-2,00000	0,99999	0,00002
11	1,00000	-2,00000	1,00000	0,00001
12	1,00000	-2,00000	1,00000	$< 0,00001$

$$\begin{cases} x_1^{(k)} = 0,7 - 0,2x_2^{(k-1)} - 0,1x_3^{(k-1)} \\ x_2^{(k)} = -1,6 - 0,2x_1^{(k-1)} - 0,2x_3^{(k-1)} \\ x_3^{(k)} = 0,6 - 0,2x_1^{(k-1)} - 0,3x_2^{(k-1)} \end{cases}$$



Semelhante a Método JR:

$$A\vec{x} = \vec{b} \Rightarrow (L^* + I + R^*)\vec{x} = \vec{b}^*$$

mas

$$(L^* + I)\vec{x} = -R^*\vec{x} + \vec{b}^*$$

$$\Rightarrow \vec{x} = -(L^* + I)^{-1}R^*\vec{x} + (L^* + I)^{-1}\vec{b}^*$$

$$\vec{x}^{(k+1)} = B\vec{x}^{(k)} + \vec{g}$$

$$B = -(L^* + I)^{-1}R^*; \quad \vec{g} = (L^* + I)^{-1}\vec{b}^*.$$

Dados valores iniciais $\vec{x}^{(0)} = (x_1^{(0)}, \dots, x_n^{(0)})^T$,

$$(L^* + I)\vec{x}^{(k+1)} = -R^*\vec{x}^{(k)} + \vec{b}^*$$

$$L^*\vec{x}^{(k+1)} + \vec{x}^{(k+1)} = -R^*\vec{x}^{(k)} + \vec{b}^*$$

$$\vec{x}^{(k+1)} = -L^*\vec{x}^{(k+1)} - R^*\vec{x}^{(k)} + \vec{b}^*$$

Semelhante a

$$\begin{cases} x_1^{(k+1)} = & -a_{12}^* x_2^{(k)} - a_{13}^* x_3^{(k)} - \dots - a_{1n}^* x_n^{(k)} + b_1^* \\ x_2^{(k+1)} = -a_{21}^* x_1^{(k+1)} & -a_{23}^* x_3^{(k)} - \dots - a_{2n}^* x_n^{(k)} + b_2^* \\ & \vdots & \vdots & \vdots & \vdots \\ x_n^{(k+1)} = -a_{n1}^* x_1^{(k+1)} - a_{n2}^* x_2^{(k+1)} - \dots - a_{n,n-1}^* x_{n-1}^{(k+1)} & + b_n^* \end{cases}$$

Crítérios de Convergência:

$$B = -(L^* + I)^{-1}R^*$$

$$||B|| < 1$$

Crítério de Sassenfeld:

se $\max_{1 \leq i \leq n} \beta_i < 1$, com

$$\beta_i = \sum_{j=1}^{i-1} |a_{ij}^*| \beta_j + \sum_{j=i+1}^n |a_{ij}^*|,$$

o método GS converge.